

誰站在黛玉身邊？——用搭配詞看《紅樓夢》裡的「人物空間」

Woloch 論小說時提出，一個角色在書裡其實有兩個身分：一個是讀者腦中假想的完整的人，有心事、有過去；另一個是敘事實際分配給他的注意力和篇幅。兩者交會的結果，他稱為「人物空間」（character-space）：主角佔據大片空間，被壓縮的角色則隨之變扁、變窄。我第一次讀到這個說法時，一方面覺得它解釋了很多閱讀直覺，一方面又懷疑：「空間」聽起來終究像個比喻，真的能變成可以檢查的東西嗎？這份報告就是這場懷疑的實驗。我的做法是找搭配詞——那些和「黛玉」一起出現的次數明顯超過運氣水準的詞。它們正是小說在黛玉身邊反覆調動的詞彙：她做什麼、誰在她旁邊、小說習慣用什麼詞想她。如果 Woloch 是對的，這張詞表應該有自己的形狀，而不是一團散沙。

語料選了《紅樓夢》一百二十回的公版全文，約 86 萬字，取自 GitHub 的 `tennessine/corpus` 倉庫（UTF-8 純文字）。選它而不選短篇，是因為黛玉的空間本來就是在「跟幾十個角色分地盤」的過程裡形成的，人物越多，分配越看得清。處理上，先用 `openccc` 把全文轉成簡體——檢查後發現這個檔案本來就是簡體，所以這一步實際沒有改動任何字，但保留它，將來換繁體語料時流程可以直接沿用；接著按句號、驚嘆號、問號分句，用 `jieba` 分詞、去掉標點，只留五個詞以上的句子，最後得到 12,884 句、449,311 個詞。目標詞「黛玉」作為一個詞出現 548 次，「林黛玉」另有 247 次。分好的句子存在 `data/sentences.txt`，之後反覆使用，不必每次重新分。

具體的計算交給 `qhchina` 的 `find_collocates`。對每一個候選的詞，它建一張 2×2 列聯表（Evert 2008）：以黛玉的每個上下文為單位，數這個詞「出現在黛玉旁邊或沒出現、是這個詞或不是」；四個格子湊齊後，用 Fisher 精確檢定算 p 值——白話說，就是假如這個詞和黛玉毫無關係，光靠運氣跑到她旁邊這麼多次的機率有多大。機率越小，越不能推給運氣。檢定能問兩個方向：比運氣多，還是比運氣少。我只關心前者，所以 `alternative` 設 "greater"，單尾只測「吸引」；雙尾會把一半的機會分給我不要的「排斥」方向。`filters` 設 `min_word_length=2`，只看兩個字以上的詞；`max_p=0.05`，保證表裡每一個詞的 p 值都過關；停用詞用 `load_stopwords()`（806 個）。另外，一次檢定幾千個詞，總會混進幾個純靠運氣過關的假顯著，所以我又做了 Benjamini-Hochberg 的 FDR 校正——校正後三種設定全部通過，結果比預期穩。「一起出現」則試了三種算法：視窗 `horizon=5`（黛玉左右各五個詞）、`horizon=10`，和句子法（同一句就算共現），各存一份 CSV，整理在 `output/results.html` 對照著看。

三種設定跑完，最先注意到的是核心的穩定：前三名完全一樣——宝玉（共現 74、141、176 次，obs/exp 約 2.0 - 2.2）、宝钗（obs/exp 約 5.4 - 6.6）、紫鹃（obs/exp 約 10.3 - 11.6），三種設定共有的搭配詞有 364 個。我又用 logDice 和 t-score 兩種不同的排序檢查，前十名照樣以人物名為主（紫鹃、宝钗、湘云、宝玉、探春），可見核心關係不是哪一種算法造出來的。

設定	搭配詞數	第一名	第二名	第三名
window h5	616	宝玉 (74)	宝钗 (36)	紫鹃 (27)
window h10	858	宝玉 (141)	宝钗 (54)	紫鹃 (54)
sentence	2,772	宝玉 (176)	宝钗 (76)	紫鹃 (72)
前80回 h5	433	宝玉 (55)	宝钗 (32)	湘云 (18)
後40回 h5	319	紫鹃 (23)	只見 (11)	起来 (11)

半徑一變，畫面上的人會換。視窗從五開到十，雪雁從第 24 名升到第 12 名（obs/exp=12.8，是共現十次以上的詞裡最高的），贾母卻從第 7 名（obs=19，exp=11.74，p=0.0304）直接掉出榜外——她出場都在場合裡，隔著幾個人的距離；雪雁是在稍遠處站著的丫鬟，視窗開大才進入範圍。句子法補上的是另一批詞：姑娘（第 8）、姊妹、众人、王夫人（第 16），全是「同在一個場景、但不貼身」的共在。贾母又是最好的例子：句子法裡她排第 5，視窗 h5 勉強第 7，h10 完全不見——祖孫的親近是場合性的，不是身體性的。另外，眼泪（h5 第 60、h10 第 47）和心中（h5 第 13）在榜上，「還淚」和高頻的心理描寫都有跡象；只是哭、病、笑這些單字詞被 min_word_length=2 擋在門外，這個損失後面再談。

整個分析裡最讓我吃驚的，是前 80 回和後 40 回的倒轉。我把語料按章回切開重跑——中間還修了一個 bug：這個語料檔把第 100 回寫成「第一零零回」，沒有「百」字，第一版切分因此把後 40 回大部分切錯了；修正後前 80 回 8,968 句、後 40 回 4,021 句，比例才正常。重跑的結果：前 80 回第一名是宝玉（obs=55），紫鹃只排第 23（obs=4）；後 40 回宝玉從 319 個顯著搭配詞裡完全消失，紫鹃變成第一名（obs=23，obs/exp=8.3），点点头（obs/exp=19.3）、光景、漸漸這種衰弱的詞湧了進來。兩個時期連「誰能在場」都不一樣：前 80 回 top30 獨有的是詩社群像（妙玉、宝琴、惜春、迎春）和黛玉的標誌動作冷笑——文本裡的她會當眾說「不过是贫嘴贱舌讨人厌恶罢了」、說著便啐了一口，句子擲地有聲；後 40 回獨有的卻是伤感、屋里、漸漸。逐回的人物空間份額曲線（output/plot_char_space_curves.png）講的是同一個故事：黛玉份額的高點

在第 3 回（進府）、第 82 回（驚夢）、第 96-98 回（焚稿、魂歸），曲線和情節對得上。

這些數字放在一起，我覺得可以這樣讀。小說寫黛玉，幾乎總是讓固定的幾個人進入她的身體半徑：紫鵲和雪雁的 obs/exp 那麼高，表示她們幾乎只出現在黛玉附近，主僕關係在詞頻上被證實了。比較意外的是寶釵：她的 obs/exp 是寶玉的好幾倍。寶玉次數多，是因為他到處都在；寶釵的每次出現卻更「準」地指向黛玉——金玉良緣的壓力，讓這兩個人話語層面被反覆放在一起。所以在 Woloch 之外我想補一句：人物空間不只看「分到多少」，還要看「跟誰分享」；寶玉是黛玉空間的背景密度，寶釵是它的結構界標。後 40 回的故事則更殘酷：黛玉的空間份額平均反而略高（0.16% 對前 80 回的 0.10%）——別的角色陸續退場，鏡頭集中到她身上——但份額變高的同時，內容在縮水：情人不見了，身邊只剩丫鬟；冷笑沒有了，變成點點頭。用 Woloch 的話說，這是一個正在關閉的人物空間：小說還在看著她，分給她的詞卻已經換了一批，她的可能性被收窄到死亡。這種收縮靠細讀也能感覺到，但搭配詞把它變成了一組可以檢查的數字。

當然，這個方法的邊界也很清楚。視窗大小是我自己選的，h5 看貼身、h10 看社交，並沒有標準答案；賈母在兩個視窗之間的消失就是提醒——空間的邊界有一部分是我畫的。目標詞同樣影響結果：把「黛玉」和「林黛玉」合併重跑後，top-50 只有 36 個相同；全名多出現在敘述性的句子裡（怡紅院、母親），單名多出現在直接的場景裡，連稱呼都是敘事的選擇。兩個字以上的門檻把哭、病、淚擋在外面，而「還淚」恰是黛玉的核心；停用詞表是現代漢語的，用在清代白話上只是近似；jieba 會分錯詞；「他／她」被當成停用詞，小說用代詞說黛玉的地方，這個方法完全看不見。最根本的是，搭配詞只數「一起出現」，不懂意思：分不清諷刺和讚美，也看不見用「不在場」構成的空間。做完這次分析，我最大的體會反而是方法的邊界：統計說得出誰在黛玉身邊，說不出為什麼是她們。Woloch 的「人物空間」最後仍是一種批評判斷，統計做的事情，是讓這個判斷有數字可以站得住。