

誰站在黛玉身邊？——用搭配詞看《紅樓夢》裡的「人物空間」

Woloch 論小說時提出，一個角色在書裡其實有兩個身份：一個是讀者腦中假想的完整的人；另一個是敘事實際分配給他的注意力和篇幅。兩者交會的結果，他稱為「人物空間」（character-space）：主角佔據大片空間，被壓縮的角色則隨之變扁、變窄。我認為這個說法可以解釋很多閱讀直覺；既然「空間」是話語分出來的，那詞頻就是最直接的證據。這份報告就是試著把「黛玉佔據了多少空間、空間裡有什麼」變成一張統計表：列出所有跟黛玉出現次數明顯超過隨機水準的詞。根據 Woloch 的理論，這張表不該是一團散沙，而應該有自己的形狀。

選用《紅樓夢》作為文本，是因為《紅樓夢》中有大量角色，角色之間又有大量錯綜複雜的關係，很適合用來解析空間分配。語料選了《紅樓夢》一百二十回的公版全文，約 86 萬字，取自 GitHub 的 `tennessine/corpus` 倉庫（UTF-8 編碼的純文字）。選它而不選短篇，是因為黛玉的空間本來就是在「跟幾十個角色分地盤」的過程裡形成的，人物越多，分配越看得清。處理上，先用 `openccc` 把全文轉成簡體（這個檔案本來就是簡體，理論上無需改動，但為流程完整保留這一步驟）；接著按照標點符號分句，用 `jieba` 分詞、去掉標點，只留五個詞以上的句子，最後得到 12,884 句、449,311 個詞。目標詞「黛玉」作為一個詞出現 548 次，「林黛玉」另有 247 次。

具體的計算交給 `qhchina` 的 `find_collocates` 函式。對每一個候選的詞，它建了一張 2×2 列聯表：窗口設定下是黛玉前後各五個或十個詞，句子設定下則是包含黛玉的整句——再數這個詞「出現在黛玉旁邊或沒出現、是這個詞或不是」；列聯表構建後，用 Fisher 精確檢定算 p 值——假如這個詞和黛玉毫無關係，光靠隨機性出現在她旁邊這麼多次的機率有多大。機率越小，越不能推給隨機性。檢定能問兩個方向：比隨機多，還是比隨機少。檢驗方向（`alternative`）設為 "`greater`"，採單尾，只檢驗「共現高於隨機期望」的吸引假設；這是因為本研究只關心吸引，雙尾會把部分顯著水準分給不處理的「排斥」方向。`filters` 設 `min_word_length=2`，僅保留兩個字以上的詞；`max_p=0.05`，使表中每一列的 p 值都低於 0.05；停用詞由 `load_stopwords()` 載入（806 個）。共現單位比較三種設定：視窗 `horizon=5`（黛玉左右各五個詞）、`horizon=10`，與句子法（同一句即為共現），各存一份結果，彙整於 `output/results.html` 對照。

三種設定跑完，最明顯的結果是：前三名完全一樣——宝玉（共現 74、141、176 次，obs/exp 約 2.0 - 2.2）、宝钗（obs/exp 約 5.4 - 6.6）、紫鹃（obs/exp 約 10.3 - 11.6），三種設定共有的搭配詞有 364 個。換一種排序方法再檢查，前十名照樣以人物名為主（紫鹃、宝钗、湘云、宝玉、探春），可見核心關係不是哪一種算法造出來的。

設定	搭配詞數	第一名	第二名	第三名
window h5	616	宝玉 (74)	宝钗 (36)	紫鹃 (27)
window h10	858	宝玉 (141)	宝钗 (54)	紫鹃 (54)
sentence	2,772	宝玉 (176)	宝钗 (76)	紫鹃 (72)
前80回 h5	433	宝玉 (55)	宝钗 (32)	湘云 (18)
後40回 h5	319	紫鹃 (23)	只見 (11)	起来 (11)

隨著半徑的改變，畫面上的人也會改變。視窗從五開到十，雪雁從第 24 名升到第 12 名（obs/exp=12.8，是共現十次以上的詞裡最高的），贾母卻從第 7 名（obs=19，exp=11.74，p=0.0304）直接掉出榜外。這是個有意思的現象，我猜測是因為贾母的出場都在公眾場合裡，隔著幾個人的距離；雪雁是在稍遠處站著的丫鬟，視窗開大才進入範圍。句子法補上的是另一批詞：姑娘（第 8）、姊妹、众人、王夫人（第 16），她們的特徵都是「同在一個場景、但不貼身」。同時，贾母又是最好的例子：句子法裡她排第 5，視窗 h5 勉強第 7，h10 完全不見。祖孫的親近是場合性的，不是身體性的。另外，眼泪（h5 第 60、h10 第 47）和心中（h5 第 13）在榜上，「還淚」和高頻的心理描寫都有跡象。

整個分析裡最讓我意外的，是前 80 回和後 40 回的倒轉。我把語料按章回分成前八十回和後四十回分別重跑。結果：前 80 回第一名是宝玉（obs=55），紫鹃只排第 23（obs=4）；後 40 回宝玉從 319 個顯著搭配詞裡完全消失，紫鹃變成第一名（obs=23，obs/exp=8.3），点点头（obs/exp=19.3）、光景、渐渐這種衰弱的詞湧了進來。兩個時期連「誰能在場」都不一樣：前 80 回 top30 獨有的是詩社群像（妙玉、宝琴、惜春、迎春）和黛玉的標誌動作冷笑——「不过是贫嘴贱舌讨人厌恶罢了」，說著便啐了一口，她最尖銳的話總是這樣當眾說出來的；後 40 回獨有的卻是伤感、屋里、渐渐。逐回的人物空間份額曲線（output/plot_char_space_curves.png）講的是同一個故事：黛玉份額的高點在第 3 回（進府）、第 82 回（驚夢）、第 96-98 回（焚稿、魂歸），與曲線和情節都有呼應。

這些數字放在一起，我覺得可以這樣解讀。小說寫黛玉，幾乎總是讓固定的幾個人進入她的身體半徑：紫鵲和雪雁的 obs/exp 那麼高，表示她們幾乎只出現在黛玉附近，主僕關係在詞頻上被證實了。說實話，這個結果改變了我對黛玉的印象：以前讀《紅樓夢》，注意力都在情節上；現在把詞頻拉出來看，才發現她的日常原來是這麼小的一個世界——一個丫鬟、一位外祖母、一群姊妹、一個寶玉，榜上再沒有賈府牆外的人。比較意外的是寶釵：她的 obs/exp 是寶玉的好幾倍。寶玉次數多，是因為他到處都在；寶釵的每次出現卻更「準」地指向黛玉——金玉良緣的壓力，讓這兩個人在話語層面被反覆放在一起。所以在 Woloch 之外我想補一句：人物空間不只看「分到多少」，還要看「跟誰分享」；寶玉是黛玉空間的背景密度，寶釵是它的結構界標。紫鵲的 obs/exp 將近十一倍，也正好回應了 Woloch 對次要角色的觀察：紫鵲的「空間」幾乎全部是從黛玉那裡借來的。小說提到她，幾乎必定是因為黛玉在場；反過來，黛玉的日常也靠這些人守著，主僕彼此定義。角色不是孤立的點，而是互相擠壓、互相填充的一片場域。後 40 回的故事則更殘酷：黛玉的空間份額平均反而略高（0.16% 對前 80 回的 0.10%），別的角色陸續退場，鏡頭集中到她身上。但份額變高的同時，內容在縮水：情人不見了，身邊只剩丫鬟；冷笑沒有了，變成點點頭。用 Woloch 的話說，這是一個正在關閉的人物空間：小說還在看著她，分給她的詞卻已經換了一批，她的可能性被收窄到死亡。這種收縮靠細讀也能感覺到，但搭配詞把它變成了一組可以檢查的數字。我也因此體會到「壓縮」是怎麼發生的：作者不會宣布某個角色不重要，他只是做了一次又一次小小的取捨——這一句讓她沉默，那一句讓別人開口——取捨累積成詞頻，詞頻累積成我們讀到的命運。

當然，這個方法的邊界也很清楚。視窗大小是我自己定的，h5 針對親密關係、h10 針對社交關係，並沒有標準答案；賈母在兩個視窗之間的消失就是提醒，空間的邊界有一部分是我界定的。目標詞同樣影響結果：把「黛玉」和「林黛玉」合併重跑後，top-50 只有 36 個相同；全名多出現在敘述性的句子裡（怡紅院、母親），單名多出現在直接的場景裡，連稱呼都是敘事的選擇。兩個字以上的門檻把哭、病、淚擋在外面，而「還淚」恰是黛玉的核心；停用詞表是現代漢語的，用在清代白話上只是近似；jieba 會分錯詞；「他 / 她」被當成停用詞，小說用代詞說黛玉的地方，這個方法完全看不見。最根本的是，搭配詞只數「一起出現」，不懂意思：分不清諷刺和讚美，也看不見用「不在場」構成的空間。做完這次分析，我最大的體會反而是方法的邊界：統計說得出誰在黛玉身邊，說不出為什麼是她們。這個「為什麼」，大概永遠只能回到文本裡去猜；但至少從今以後，我的猜測不再空手憑印象，身後有一張詞頻表可以對照。Woloch 的「人物空間」最後仍是一種批評判斷，統計做的事情，是讓這個判斷有數字可以站得住。